

Uczenie Maszynowe

Laboratorium 7: Klasteryzacja

Przemysław Dolata

7.6.2026

Cel laboratorium

Celem laboratorium jest nabycie umiejętności stosowania algorytmów klasteryzacji w praktyce. W odróżnieniu od przykładów z tutorialu, rzeczywiste dane rzadko kiedy układają się w klarowne, wyraźnie odseparowane klastry. Ponadto wizualna ocena wyników staje się ograniczona z powodu wymiarowości przestrzeni danych. Z tej przyczyny poprowadzisz badania w oparciu o ilościowe metryki jakości klasteryzacji.

Zbiór danych

Do tej listy powinien być dołączony plik `Dry_Bean_Dataset.zip`, archiwum zawierające zbiór danych Dry Bean Dataset 1. Zbiór ten przedstawia kolekcję ziaren fasoli 7 różnych gatunków. Został pozyskany w dwóch krokach: najpierw wykonano fotografie ponad 13 tysięcy ziaren, a następnie każde z nich cyfrowo zmierzono i opisano za pomocą zbioru cech takich jak pole powierzchni, obwód, współczynnik kształtu, wklęsłość, okrągłość etc. (pełna lista na stronie zbioru). Jeśli interesują Cię szczegóły, znajdziesz je w oryginalnej publikacji autorów 2.

Zbiór zapisany jest w formacie ARFF, do zaczytania którego będzie konieczne użycie pakietu `scipy`:

```
from scipy.io import arff
source = arff.loadarff('path/to/file.arff')
df = pd.DataFrame(source[0])
```

Zadania

1 Analiza zbioru danych

Dokonaj eksploracyjnej analizy danych. Powinna obejmować co najmniej przegląd statystyk zbioru oraz wizualizacje dystrybucji danych. Nie pokazuj wszystkich możliwych wykresów cech parami, gdyż będzie ich zwyczajnie zbyt dużo; zidentyfikuj i przedstaw wyłącznie interesujące pary. Podejmij na tym etapie decyzje dotyczące wstępnego przetwarzania.

2 Algorytm k-średnich

2.1 Przygotowanie

Uruchom algorytm k-średnich (`sklearn.cluster.KMeans`, 4) na przetworzonym zbiorze danych. Na ten moment przyjmij dowolną liczbę k . Odczytaj wartość miary *inerencji* grupowania.

Opracuj funkcję do wizualizacji wyniku klasteryzacji; możesz posłużyć się przykładami z tutorialu, ale zadбай o dopasowanie ich do zbioru danych użytego w tej części listy (patrz: sekcja o analizie danych).

2.2 Badanie wpływu parametru k

Używając przygotowanej powyżej infrastruktury, wykonaj badanie wpływu liczby klastrów na działanie algorytmu.

Przedstaw na wykresach wpływ k na inercję oraz na miary jakości grupowania: *silhouette* oraz *purity*.

Wybierz najistotniejsze wartości k i zwizualizuj uzyskane dla nich wyniki.

Co to znaczy „optymalna” wartość k i w jaki sposób ją wybrać?

3 Klasteryzacja aglomeracyjna

Innym podejściem do klasteryzacji jest grupa metod aglomeracyjnych (hierarchicznych). Tej klasy algorytmy działają na zasadzie „bottom-up”: rekurencyjnie łącząc punkty danych według zadanej reguły, budując klastry aż do osiągnięcia pewnego kryterium. Omówienie podstaw działania algorytmów tej klasy znajdziesz w podręczniku użytkownika pakietu `scikit-learn` 5.

3.1 Badanie

Podobnie jak w przypadku k-średnich, najistotniejszym parametrem metody jest pożądana liczba klastrów¹. Przeprowadź badanie wpływu tego parametru na wyniki klasteryzacji algorytmem aglomeracyjnym.

Nie zmieniaj pozostałych parametrów, w szczególności pozostań przy metryce euklidesowej i kryterium łączenia `ward` (w przypadku uzyskania wyraźnie niesatysfakcjonujących wyników możesz przetestować inne strategie). Wyniki, jak poprzednio, przedstaw na wykresach i wizualizacjach. Zadбай o to, by możliwe było wygodne porównanie działania obu badanych w liście algorytmów.

3.2 Pomiar czasu

Zmierz i porównaj czas działania algorytmów k-średnich i aglomeracyjnego; uwzględnij wyniki tego porównania we wnioskach. Dowiedz się, w jaki sposób przeprowadzić metodologicznie poprawny pomiar czasu działania algorytmu w języku Python.

¹Aczkolwiek w odróżnieniu od k-średnich możliwe jest stosowanie również innych kryteriów stopu.

Literatura

1. Zbiór danych *Dry Bean Dataset*
2. Oryginalna publikacja: Koklu, M., and Ozkan, I. A., (2020) Multiclass Classification of Dry Beans Using Computer Vision and Machine Learning Techniques. *Computers and Electronics in Agriculture*, 174, 105507.
3. Podręcznik użytkownika pakietu `scikit-learn`: klasteryzacja
4. Dokumentacja algorytmu k-średnich w pakiecie `scikit-learn`
5. Podręcznik użytkownika pakietu `scikit-learn`: klasteryzacja hierarchiczna
6. Dokumentacja algorytmu klasteryzacji aglomeracyjnej w pakiecie `scikit-learn`
7. Materiały do wykładu